Kontrola typové koherence kontstrukcí Transparentní intenzionální logiky

Filip Peterek

9. červen 2022

1 Cíl práce

Cílem práce bylo vytvoření programu umožňujícího kontrolu typové koherence konstrukcí Transparentní intenzionální logiky. Program měl na svém vstupu přijímat konstrukce, na svém výstupu měl vrátit seznam případných chyb, a graficky znázornit průběh typové kontroly za využití grafu.

Program je psán v programovacím jazyce Kotlin, jako build systém byl zvolen Gradle.

V současném stavu je program CLI aplikací. Při spouštění lze programu předat libovolný počet souborů jako CLI argumenty. Tyto soubory jsou poté postupně zpracovány programem. Program všechen svůj výstup vytvoří ve složce, ze které byl spuštěn. Pro každý vstupní soubor jsou vytvořeny nanejvýš dva výstupní soubory, textový výstup ve formátu JSON [5] popisující vstupní TIL-Script program, a graf typové kontroly ve formátu SVG [4]. Název výstupního souboru je definován jako název vstupního souboru, za něž je pouze dodána přípona odpovídající danému formátu. Soubory nemusí být vytvořeny, pokud je vytvořit nelze (např. z důvodu chyby ve vstupním programu). Žádné přepínače poté program neočekává.

2 Transparentní intenzionální logika

Transparentní intenzionální logika [1] (dále také pouze TIL) je logický systém sloužící k analýze přirozeného jazyka. TIL vychází z typovaného lambda kalkulu, a využívá rigorózně definovaný typový systém za účelem zabránění velké škále chyb. Mezi chyby, které lze typovým systémem zachytit, patří například primitivnější chyby, jako je špatné pořadí argumentů (rovnice počítá Karla), ale také chybná změna supozice způsobená inkorektní analýzou (funkce očekává úřad, avšak na vstupu dostane individuum). Kontrolu typové koherence však lze provádět strojově. Tato práce se zabývá automatizací typové kontroly, jež je užitečná převážně v případě, kdy analyzujeme složité TIL konstrukce a manuální typová kontrola by tedy byla náchylná k chybě.

2.1 TIL-Script

TIL-Script [2] je funkcionální programovací jazyk sloužící k práci s TIL konstrukcemi. Syntax TIL-Scriptu vychází z notace TIL, kterou je však upravena pro potřeby počítačového zápisu – zatímco TIL ve své notaci hojně využívá řecké abecedy nebo horních i dolních indexů, TIL-Script byl vytvářen tak, aby byl jednoduše zapisovatelný i na běžné klávesnici. Z toho důvodu byl také TIL-Script zvolen jako notace využívaná v této práci.

3 Implementace

3.1 Parser jazyka TIL-Script

Parser byl vygenerován za využití generátoru parserů Antlr [3]. Díky volby již existujícího jazyka jako notace programu stačilo gramatiku jazyka TIL-Script upravit do formátu zpracovatelného Antlrem. Jelikož program pro kontrolu typové koherence využívá build systém Gradle, je parser automaticky vygenerován během kompilace, je-li to potřeba. Výstup vygenerovaného parseru je poté převeden na vlastní reprezentaci, která je méně generická a umožňuje ergonomičtější programatickou práci s abstraktním syntaktickým stromem TIL-Script programu.

Ke kontrole syntaktických chyb je využita kontrola zabudovaná do nástroje Antlr. Nad rámec automatického reportování zabudovaného v Antlru je implementován pouze vylepšený indikátor pozice chyby přímo ve strojovém kódu, a kromě číselné pozice chyby je vypsán také samotný chybný řádek s graficky vyznačenou chybou.

3.2 Kontrola existence symbolů

Aby bylo možné provést typovou kontrolu, je třeba znát typy všech symbolů, které se ve vstupní konstrukci nacházejí. Proto tvorbu abstraktního syntaktického stromu následuje právě kontrola, zda jsou všechny symboly definovány. Symbol může být definován jako literál (např. Karel, Vysoká škola báňská), funkce, proměnná libovolného typu, nebo jako typový alias (ekvivalent např. `typedef` známého z jazyků C a C++). Typové aliasy, literály a funkce lze definovat pouze pomocí samostatné TIL-Script definice. Proměnné lze definovat pomocí globální definice definující volnou proměnnou, nebo jako λ-vázanou proměnnou v konstrukci uzávěru. Symbol musí být definován před jeho prvním použitím.

Proměnné vázané trivializací také musí být definované. Ačkoliv proměnné vázané trivializací nejsou konstituenty, neboť trivializace konstruuje konstrukci proměnné, tedy typ $*_n$, program provádí typovou kontrolu všech podkonstrukcí.

V případě, že se vstupní program odkazuje na alespoň jeden nedefinovaný symbol, je běh programu ukončen a na standardní výstup jsou vypsány všechny využívané, avšak nedefinované symboly. K typové kontrole nedojde, neboť ji nejde provést.

Program automatickou dedukci typů symbolů nepodporuje.

3.3 Kontrola typové koherence

Kontrola typové koherence vyžaduje průchod stromem a proto je, přirozeně, implementována rekurzivně. Při kontrole každé konstrukce jsou zkontrolovány nejprve její podkonstrukce (všechny podkonstrukce, nejen konstituenty). Podkonstrukce jsou zkontrolovány, zda jsou typově koherentní, a je jim přirazen datový typ, který konstruují. Teprve poté je zkontrolována původní konstrukce. Atomickým konstrukcím, tedy proměnným, literálům a funkcím, je jejich typ přirazen rovnou.

V kompozici, tedy při aplikaci funkce, je třeba zkontrolovat, že je funkce aplikována na správný počet argumentů, a že všechny typy argumentů odpovídají typům dle signatury funkce. V opačném případě samozřejmě typová kontrola selhává a na standardní výstup je vypsána chyba.

Selže-li typová kontrola v některé z podkonstrukcí, typová kontrola konstrukce samotné selhává také, neboť ji nelze provést. V takovém případě však není vypisována žádná chyba, neboť program v současné verzi nedokáže určit, zda by k chybě došlo. Typ konstruovaný konstrukcí je označen za neznámý. Jelikož kontrola existence symbolů byla provedena již v předchozím kroku, lze v tomto kroku přítomnost neznámého typu interpretovat právě jako selhání typové kontroly.

Datové typy jsou konstrukcím přiřazovány teprve při úspěšném dokončení typové kontroly pro danou konstrukci. Důvodem této implementace je existence typově polymorfních funkcí, u kterých nemusí být předem jednoznačně určen konstruovaný typ.

Při typové kontrole je nutné brát v potaz vázání proměnných. Proto je pro každou trivializaci konstrukce, jež není literál nebo funkce, a pro každý uzávěr konstruován nový kontext. Kontext trivializace je nezávislý na kontextu nadkonstrukce, odkazuje se pouze na globální kontext, jež obsahuje informace o volných proměnných a funkcích. Kontext uzávěru se na kontext nadkonstrukce odkazuje, umožňuje však definovat λ-vázané proměnné, jež zastíní proměnné z rodičovských kontextů. Při nalezení symbolu jsou poté kontexty prohledávány rekurzivně, od nejbližšího kontextu až po kontext globální, a je hledán typ konstruovaný symbolem. Globální kontext je samozřejmě nezávislý na kontextech uzávěrů a trivializací. Lze jej modifikovat pouze globální definicí.

Dále je důležité vyřešit porovnávání uživatelem definovaných typových aliasů a typů jimi reprezentovanými. Při porovnávání typů jsou vždy všechny aliasy rekurzivně expandovány, dokud se datový typ neskládá pouze z typů zabudovaných přímo do jazyka TIL-Script. Teprve takto plně expandované typy se mezi sebou porovnávají. Tento způsob porovnávání uživatelem definovaných typů byl zvolen zejména proto, že TIL-Script neumožňuje definici nového typu např. definicí struktury složené z více hodnot již existujících typů, ale pouze definici nového názvu pro již existující typ.

Dvojité provedení není kontrolováno, neboť pro něj obecně není možné korektně určit konstruovaný typ.

3.4 Rozpoznání kontextu

Po dokončení typové kontroly je provedeno také rozpoznání kontextu. V tomto kroku se pouze rozhoduje, zda se jednotlivé konstrukce nachází ve výskytu hyperintenzionálním, intenzionálním, či extenzionálním. Informace o výskytu se nachází pouze v textovém výstupu programu, graficky momentálně výskyt nijak znázorňován není.

Implementace je opět rekurzivní. Program rekurzivně vyhodnocuje výskyt vstupní konstrukce a poté všech jejich podkonstrukcí. Zároveň vždy uchovává informaci o nejvyšším nadřazeném kontextu, neboť je při rozpoznávání kontextu nutné kontrolovat, zda se konstrukce nenachází ve vyšším nadřazeném kontextu. V takovém případě se totiž výskyt konstrukce rovná výskytu nadřazenému.

4 Výstup programu

4.1 Grafický výstup

Jako formát grafického výstupu byl zvolen vektorový grafický formát SVG. Opodstatněními volby tohoto formátu jsou jeho jednoduchost a textová nátura, jež umožňují jednoduché generování SVG obrázků, rozšířenost formátu, ale také vektorová charakteristika, díky které lze SVG obrázky libovolně škálovat bez ztráty kvality [4].

Grafický výstup znázorňuje pouze průběh typové kontroly. Chyby či výskyty konstrukcí znázorňovány nejsou.

V grafu je znázorněna nejen původní konstrukce, ale hlavně také typy konstruované konstrukcí samotnou i jejími podkonstrukcemi. Pro textový výpis konstrukcí a typů byl zvolen neproporcionální font. Tato volba umožňuje přesně spočítat pozici každého znaku, protože všechny znaky mají nutně stejnou šířku. Tento fakt je využit při definici čar spojujících konstrukce a typy. Jelikož názvy typů můžou být v jazyce TIL-Script relativně dlouhé, musí být typy, ale konstrukce tyto typy konstruující, odsazeny, aby nedošlo k překrývání textu. Ukázku grafu typové kontroly lze vidět na obrázku 1.

Algoritmus tvorby grafu typové kontroly byl psán ručně, nejsou použity žádné knihovny třetí strany.

4.2 Textový výstup

4.2.1 Standardní výstup

Jelikož se jedná o CLI aplikaci, program k interakci s uživatelem využívá standardní výstup. Na standardní výstup program vypisuje chyby ve vstupních souborech – o jakou chybu se jedná, na jaké pozici se chyba nachází, a také úryvek relevantního kódu se znázorněnou chybou.

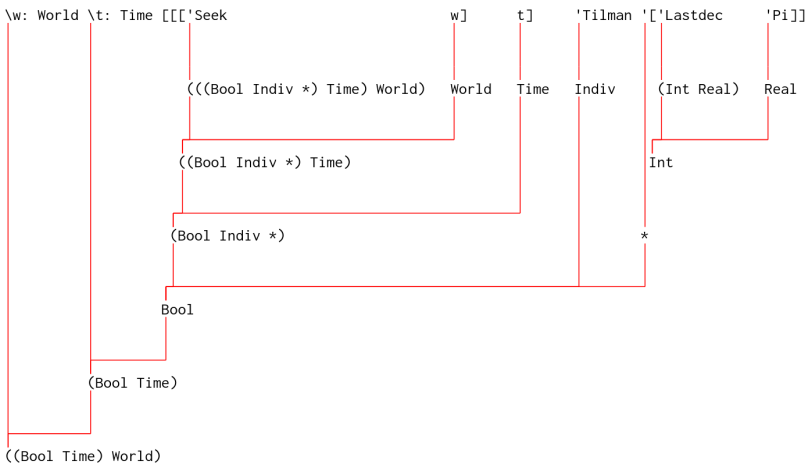

Obrázek 1: Ukázka grafu typové kontroly

4.2.2 JSON výstup

Výstup ve formátu JSON je zapsán do souboru. JSON výstup obsahuje informace o obsahu souboru – jaké konstrukce se v něm nachází, podkonstrukce jednotlivých konstrukcí, typ konstruovaný každou konstrukcí, typ konstrukce, ale také výskyt konstrukce. Z JSON souboru lze plně zrekonstruovat vstupní soubor, s výjimkou formátování textu.

Důvodem volby formátu JSON byly převážně plány rozšířit v budoucnu program o webovou aplikaci nebo jazykový server. Protokol LSP dle svého standardu ke komunikaci využívá formát JSON. Ve webových aplikacích je poté formát JSON víceméně standard díky všudypřítomnosti jazyka Javascript. Formát JSON je samozřejmě pro aktuální aplikaci velmi dobře využitelný, neboť slouží ke kódování stromových struktur [5], které jsou pro reprezentaci konstrukcí složených z podkonstrukcí velmi praktické.

5 Závěr

Zadáním projektu bylo implementovat typovou kontrolu a znázornit ji pomocí grafu. Zadání bylo splněno. Program je dále možné rozšířit například o implementaci protokolu LSP [6], což by umožnilo ergonomičtější tvorbu a editaci TIL-Script programů v editorech implementujících tento protokol. Alternativně by bylo možné vytvořit interaktivní webovou službu umožňující provádět typovou kontrolu v prohlížeči.

Reference

[1] Duží, M., Materna, P.: *TIL jako procedurální logika*
Marie Duží, Pavel Materna, 2012

[2] Ciprich, N., Duží, M., Košinár, M.: *TIL-Script: Functional Programming Based on Transparent Intensional Logic*
In: *RASLAN 2007*, Sojka, P., Horák, A., (Eds.), Masaryk University Brno, 2007, pp. 37–42.

[3] Parr, T.: *ANTLR v4* [online, cit. 2022-06-09]
Dostupné z: `https://www.antlr.org`
Terence Parr

[4] W3C: *Scalable Vector Graphics (SVG) 2* [online, cit. 2022-06-09]
Dostupné z: `https://www.w3.org/TR/SVG2/`
World Wide Web Consorcium

[5] ECMA: *JSON* [online, cit. 2022-06-09]
Dostupné z: `www.json.org`
ECMA

[6] Microsoft: *Language Server Protocol* [online, cit. 2022-06-09]
Dostupné z: `https://microsoft.github.io/language-server-protocol/`
Microsoft